


10. STATISTIKA

10.1 TOČKASTE PROCJENE



X sluč. varijabla, populacija

$\rightsquigarrow F, f, m, \sigma^2$

$\rightsquigarrow F$ može ovisiti o nekim parametrima

$\theta_1, \dots, \theta_k$

def

Za X_1, \dots, X_n slučajne varijable kažemo da su nezavisne kopije slučajnih varijabli X ako vrijedi:

1) X_1, \dots, X_n nezavisne

2) $X_i \sim F$

(X_1, \dots, X_n) UZORAK

(X_1, \dots, X_n) REALIZACIJA

→ pretpostavimo da razdioba F ovisi samo o θ :

$$F(x) = F_{\theta}(x)$$

$$f(x) = f_{\theta}(x)$$

→ θ procijeniti pomoću X_1, \dots, X_n

$$\hat{\theta} = g(X_1, \dots, X_n) \quad \text{procjena za } \theta$$

$$\theta = g(X_1, \dots, X_n) \quad \text{STATISTIKA}$$

$g(X_1, \dots, X_n) \rightarrow$ statistika

θ procjenitelj parametra θ

$\hat{\theta}$ procjena parametra θ

Pitanja: 1) Koje statistike su dobre za m i σ^2 ?
2) Što su to dobre statistike ?

→ statistika za procjenu očekivanja $a = E(X)$:

$$\bar{X} = \frac{1}{n} \cdot (X_1 + \dots + X_n) \quad \text{SREDINA UZORKA}$$

↳ slučaj. varijable, statistika

$$E[\bar{X}] = \frac{1}{n} [E(X_1) + \dots + E(X_n)] = \frac{1}{n} \cdot n \cdot a = a //$$

$$D(\bar{X}) = \frac{1}{n^2} [D(X_1) + \dots + D(X_n)] = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n} //$$

→ DOBRE STATISTIKE:

1) $\theta =$ NEPRISTRANA STATISTIKA (procenitelj) za ϑ ako je

$$E(\theta) = \vartheta$$



→ \bar{x} nepristrani procenitelj za očekivanje

2) Ako niz statistika $\theta_n = \theta_n(x_1, \dots, x_n)$ konvergira po vjerovatnosti prema parametru ϑ tada θ_n zovemo VALJANOM STATISTIKOM

$$\forall \varepsilon > 0 \quad P(|\theta_n - \vartheta| \geq \varepsilon) \rightarrow 0 \quad n \rightarrow \infty$$

3) θ_1 i θ_2 dvije nepristrane statistike za ϑ

→ θ_1 bolja od θ_2 ako $D(\theta_1) < D(\theta_2)$

TM

NEPRISTRANA STATISTIKA je VALJANA ako joj disperzija teži k 0.

DOKAZ:

$$E[\theta_n] = \vartheta \quad D(\theta_n) \rightarrow 0 \quad n \rightarrow \infty \quad \text{želimo: } \theta_n \xrightarrow{P} \vartheta$$

$$0 \leq P(|\theta_n - \vartheta| \geq \varepsilon) \leq \underbrace{\frac{D(\theta_n)}{\varepsilon^2}}_{\text{Čebiš.}} \rightarrow 0 \quad \Rightarrow \quad \curvearrowright$$

→ \bar{x} valjana za σ zbog:

$$D(\bar{x}) = \frac{\sigma^2}{n} \rightarrow 0 \quad \checkmark$$

→ STATISTIKA ZA PROCJENU DISPERZIJE:

→ a poznat: $D^2 = \frac{1}{n} \sum_{i=1}^n (x_i - a)^2$

→ a nepoznat: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

→ D^2 i S^2 su nepristrani i valjani procjenitelji za σ^2

$$E(D^2) = \sigma^2$$

$$D(D^2) = \frac{1}{n} (\mu_4 - \sigma^4) \rightarrow 0 \quad \checkmark$$

$$\theta = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \Rightarrow E(\theta) = \frac{n-1}{n} \sigma^2$$

$$E\left[\frac{n}{n-1} \theta\right] = \sigma^2$$

$$E(S^2) = \sigma^2$$

Primjer 10.3.

→ 6 rezultata: 3540, 3582, 3559, 3572, 3564, 3584 m

a) $a = 3560$ b) a nepoznat

a) $D^2 = \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 = \frac{1}{6} \sum_{i=1}^6 (x_i - 3560)^2 = 232,17 \text{ m}^2$

b) $S^2 = \frac{1}{6-1} \sum_{i=1}^6 (x_i - \bar{x})^2 = \frac{1}{5} [(3540 - 3561.17)^2 + \dots + (1)^2] = 276,97 \text{ m}^2$

→ podaci mogu biti podijeljeni unaprijed u razrede i dati u tablici:

VRJEDNOSTI	X_1	\dots	X_2	\dots	X_r
FREKVENCije	n_1	n_2	\dots	n_r	

$n = n_1 + \dots + n_r$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^r X_i \cdot n_i$$

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^r n_i \cdot X_i^2 - n \cdot \bar{X}^2 \right)$$

Primjer 10.4.

$$\bar{X}, S^2 = ?$$

X_i	2560	2600	2620	2650	2700
n_i	2	3	10	4	1

* PODSJETNIK:

$$E(x-c) = E(x) - c$$

$$c = 2620$$

$$D(x-c) = D(x)$$

$$\bar{X} = \frac{1}{20} \sum_{i=1}^5 (X_i - 2620) n_i + 2620$$

$$\bar{X} = 2621$$

$$S^2 = \frac{1}{19} \left(\sum_{i=1}^5 n_i \cdot (X_i - 2620)^2 - n \bar{X}^2 \right)$$

$$S^2 = 967,4$$

z1-12-4.) Iz intervala $[d, 1]$ odabrano je na sreću n brojeva

$X_1, \dots, X_n \in [d, 1]$. Da bismo procijenili d odabrali smo statistiku $Y = \text{minimum}\{X_1, \dots, X_n\} - \frac{1}{n+1}$.

a) provjerite nepristranost statistike

$$E(Y) = d$$



→ Ako je očekivanje jednako pravoj vrijednosti!

$$Y = \underbrace{\min\{X_1, \dots, X_n\}}_X - \frac{1}{n+1}$$

TRIK

$$F_X(x) = P(X < x) = P(\min\{X_1, \dots, X_n\} < x) =$$

$$= 1 - P(\min\{X_1, \dots, X_n\} > x) =$$

$$= 1 - P(X_1 > x, X_2 > x, \dots, X_n > x) =$$

$$= 1 - P(X_1 > x)^n =$$

$$= 1 - \left(\int_x^1 \frac{1}{1-d} dx \right)^n$$

JEDNOLIKA

RAZDIOBA (pretp.)!

$$= 1 - \left(\frac{1-x}{1-d} \right)^n$$

$$f(x) = F'_x(x) = -n \left(\frac{1-x}{1-d} \right)^{n-1} \cdot \frac{-1}{1-d} = \frac{n}{(1-d)^n} \cdot (1-x)^{n-1}$$

$$E(x) = \int_d^1 x \cdot \frac{n}{(1-d)^n} (1-x)^{n-1} dx = \dots = \frac{n}{(1-d)^n} \left[\frac{t^n}{n} - \frac{t^{n+1}}{n+1} \right] \Big|_d^1 =$$

substit. = t

OČEKUJ →

$$= \dots = 1 - \frac{n}{n+1} (1-\alpha)$$

$$E(y) = E(x) - \frac{1}{n+1} = 1 - \frac{n}{n+1} (1-\alpha) - \frac{1}{n+1} =$$

$$= 1 - \underbrace{\frac{n}{n+1}}_{\frac{1}{n+1}} + \frac{\alpha \cdot n}{n+1} - \frac{1}{n+1} = \frac{n}{n+1} \cdot \alpha$$

⇒ Ova statistika NIJE NEPRISTRANA. ($E(y) \neq \alpha$)

b) S kojim faktorom treba pomnožiti da bude nepristrana?

→ treba pomnožiti s $\frac{n+1}{n}$

NIKAD NIJE BILO "PROVJERITI DA JE VAŽANA"

⇒ MOŽDA PROGURA OVE GODINE DA BUDE

1
2
1

$$\boxed{TM} \lim_{n \rightarrow \infty} D(x) = 0$$

10.2. KRITERIJ NAJVEĆE IZGLEDNOSTI (KNI)

(MILF)

FUNCTION
LIVELIHOOD
MAXIMUM INTENSITY

def.

Neka je x_1, \dots, x_n realizacija uzorka iz neke populacije X čija funkcija gustoće f ovisi o parametru ϑ .

Funkcija IZGLEDNOSTI se definira kao

$$L(\vartheta, x_1, \dots, x_n) = f(\vartheta, x_1) \cdot \dots \cdot f(\vartheta, x_n)$$

→ za procjenu parametra ϑ se uzima vrijednost za koju L poprima **GLOBALNI MAKSIMUM** → derivaciju izjednačiti s nulom!

↓
A ŠTO DRUGO KAD JE MILF U PITANJU

21-11-20) Uzorak x_1, \dots, x_n je izvučen iz populacije s funkcijom gustoće $f(x) = \lambda x^{\lambda-1}$. Pomocu KNI odredite λ .

$$L(\lambda, x_1, \dots, x_n) = \lambda \cdot x_1^{\lambda-1} \cdot \lambda \cdot x_2^{\lambda-1} \cdot \dots \cdot \lambda \cdot x_n^{\lambda-1}$$

$$= \lambda^n (x_1 \cdot \dots \cdot x_n)^{\lambda-1}$$

TRIK !

ZBOG KOMPLIKACIJE SA DERIVACIJOM n UMNOŽA.
PRELAZIMO NA \ln !

$$\ln L = n \ln \lambda + (\lambda-1) \ln(x_1 \cdot \dots \cdot x_n) \quad \left| \frac{\partial}{\partial \lambda} \right.$$

$$\frac{n}{\lambda} + \ln(x_1 \cdot \dots \cdot x_n) = 0$$

$$\lambda = -\frac{n}{\ln(x_1 \cdot \dots \cdot x_n)} = -\frac{n}{\ln \prod_{i=1}^n x_i} //$$

21-09-1)

$$f(x) = \frac{\lambda}{2\sqrt{x}} e^{-\lambda\sqrt{x}}, \text{ pomoću KNI odredi } \lambda.$$

maximum
likelihood
MILF
intensity
function

$$L(\lambda, x_1, \dots, x_n) = \frac{\lambda}{2\sqrt{x_1}} e^{-\lambda\sqrt{x_1}} \dots \frac{\lambda}{2\sqrt{x_n}} e^{-\lambda\sqrt{x_n}} =$$

$$= \frac{\lambda^n}{2^n \sqrt{x_1 \dots x_n}} e^{-\lambda(\sqrt{x_1} + \sqrt{x_2} + \dots + \sqrt{x_n})}$$

$\ln(e) = 1$

$$\ln L = n \ln \lambda - \underbrace{\ln 2^n \sqrt{x_1 \dots x_n}}_{\text{konstanta}} - \lambda \sum_{i=1}^n \sqrt{x_i} \quad \left| \frac{\partial}{\partial \lambda} \right.$$

$$\frac{n}{\lambda} - \sum_{i=1}^n \sqrt{x_i} = 0$$

$$\Rightarrow \lambda = \frac{n}{\sum_{i=1}^n \sqrt{x_i}}$$

21-10-1.)

Bacamo neispravan novčić. Bacili ga 5 puta i pismo se pojavilo 2 puta, zatim se u 8 puta pojavilo 3 puta. Pomoću KNI (MILF) odredite procjenu za pojavljivanja pisma.

vjerojatnost

\Rightarrow bez KNI, zdrava logika $\rightarrow \frac{5}{13} \approx 0.38$

$$L(\lambda, x_1, \dots, x_n) = P(X=x_1) \dots P(X=x_n)$$

BINOMNA RAZDIOBA

$$X_1 \sim B(5, p), X_2 \sim B(8, p)$$

$$L(p) = \binom{5}{2} p^2 (1-p)^3 \cdot \binom{8}{3} p^3 (1-p)^5 = \binom{5}{2} \binom{8}{3} p^5 (1-p)^8$$

\rightarrow DISKRETAN SLUČAJ

$$\binom{n}{k} p^k (1-p)^{n-k}$$

BINOMNA

$$\ln L = \overset{\text{konstante}}{\ln K} + 5 \ln p + 8 \ln(1-p) \quad \Bigg/ \quad \frac{d}{dp} \quad \longrightarrow \quad \text{OBIČNA DERIVAC. SAMO JEDNA VARIJABLA!}$$

$$\frac{5}{p} + \frac{-8}{1-p} = 0$$

$$p = \frac{5}{13}$$

#INT:

"NIKAD NIJE BILO S POISSONOVOM RAZDIOBOM, MOGLO BI DOĆI OVE GODINE!"

→ DISKRETNE VAR. : MNOŽIMO VJEROJATNOSTI
KONTINUIRANE VAR. : MNOŽIMO GUSTOĆE

→ KAD-TAD NA ISPITU ĆE DOĆI 10.6. (str. 13) (BILO NA ROKOVIMA...)

→ riješeni boldani zadaci u knjizi

→ 6, 7, 8. zad ne treba, ostalo DA!