

VJEROJATNOST I STATISTIKA
TEORIJA

FER, Zagreb

Marko NUFC

1. VJEROJATNOST

1. Operacije s događajima:

Unija i presjek događaja

Događaj koji se ostvaruje ako se ostvario *barem jedan* od događaja A , B naziva se **unija** ili **zbroj** (suma) događaja i označava s $A \cup B$, $A + B$, A ili B .

Događaj koji se ostvaruje ako su se ostvarila *oba* događaja A i B naziva se **presjek** ili **umnožak** (produkt) događaja i označava s $A \cap B$, AB , A i B .

2. Razlika događaja. Komplement događaja.

Razlika događaja. Komplement događaja

Događaj koji se ostvaruje ako se ostvari događaj A , a da se ne ostvari događaj B , nazivamo **razlika događaja** A i B i označavamo s $A \setminus B$, $A - B$.

Događaj $\Omega \setminus A$ nazivamo **komplementom** ili **suprotnim događajem** događaja A . On se ostvaruje ako i samo ako se A nije ostvario. Označavamo ga s \bar{A} ili s A^c .

3. De Morganovi zakoni

$$\overline{A \cup B} = \bar{A} \cap \bar{B}$$

$$\overline{A \cap B} = \bar{A} \cup \bar{B}$$

Te formule nazivamo **de Morganovi zakoni**.

Dokažimo (1):

$$\begin{aligned} \omega \in \overline{A \cup B} &\iff \omega \notin A \cup B \iff \omega \notin A \text{ i } \omega \notin B \\ &\iff \omega \in \bar{A} \text{ i } \omega \in \bar{B} \iff \omega \in \bar{A} \cap \bar{B}. \end{aligned}$$

Drugu formulu možemo pokazati na sličan način. Međutim, korisno je vidjeti da ona slijedi iz prve formule. Naime, kako za svaki događaj vrijedi $\overline{\bar{A}} = A$, možemo računati ovako

$$\overline{\overline{A \cup B}} = \text{po (1)} = \overline{\bar{A} \cap \bar{B}} = A \cup B$$

te je

$$\overline{\overline{A \cap B}} = \overline{\overline{\bar{A} \cup \bar{B}}} = \bar{A} \cup \bar{B}.$$

4. Algebra događaja

Algebra događaja

Algebra događaja je svaka familija \mathcal{F} podskupova od Ω na kojoj su definirane **binarna operacija zbrajanja** $+$: $\mathcal{F} \times \mathcal{F} \rightarrow \mathcal{F}$ i **unarna operacija komplementiranja** sa svojstvima

- 1) $\Omega \in \mathcal{F}, \emptyset \in \mathcal{F}$,
- 2) $A \in \mathcal{F} \implies \bar{A} \in \mathcal{F}$,
- 3) $A, B \in \mathcal{F} \implies A + B \in \mathcal{F}$.

Elemente algebre \mathcal{F} zovemo **događaji**.

5. Vjerojatnost

Vjerojatnost

Vjerojatnost je preslikavanje $P : \mathcal{F} \rightarrow [0, 1]$ definirano na algebri događaja \mathcal{F} , koje ima svojstva

- 1) $P(\Omega) = 1, P(\emptyset) = 0$ (**normiranost**),
- 2) ako je $A \subset B$, onda vrijedi $P(A) \leq P(B)$ (**monotonost**),
- 3) ako su A i B disjunktni događaji, onda je $P(A \cup B) = P(A) + P(B)$ (**aditivnost**).

Broj $P(A)$ nazivamo **vjerojatnost događaja** A .

6. Vjerojatnost komplementa

Neka je A po volji odabran događaj, a \bar{A} njegov komplement. Onda vrijedi $A \cup \bar{A} = \Omega$ i pritom su A i \bar{A} disjunktni. Zato, po svojstvima normiranosti i aditivnosti vrijedi

$$1 = P(\Omega) = P(A \cup \bar{A}) = P(A) + P(\bar{A}),$$

te je $P(\bar{A}) = 1 - P(A)$. Time smo pokazali:

Vjerojatnost komplementa

Za svaki događaj A vrijedi $P(\bar{A}) = 1 - P(A)$.

7. Vjerojatnost unije

Vjerojatnost unije

Za bilo koja dva događaja A i B vrijedi

$$P(A \cup B) = P(A) + P(B) - P(AB).$$

Po svojstvu aditivnosti vjerojatnosti slijedi:

$$\begin{aligned}P(A \cup B) &= P(A) + P(B\bar{A}), \\P(B) &= P(AB) + P(B\bar{A}).\end{aligned}$$

Oduzimanjem dobivamo traženu formulu:

$$P(A \cup B) - P(B) = P(A) - P(AB).$$

8. Klasična vjerojatnost

Klasična vjerojatnost

U klasičnom vjerojatnosnom prostoru vjerojatnost događaja računa se formulom:

$$P(A) = \frac{M}{N} = \frac{\text{broj povoljnih ishoda}}{\text{broj mogućih ishoda}}.$$

9. Sigma-algebra i sigma-aditivnost vjerojatnosti

σ -algebra i σ -aditivnost vjerojatnosti

Ako je Ω beskonačan skup, tad zahtjevamo da algebra događaja \mathcal{F} bude **σ -algebra**, tj. za nju vrijedi

$$A_1, A_2, \dots, A_n, \dots \in \mathcal{F} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Vjerojatnost P na σ -algebri \mathcal{F} mora zadovoljavati uvjet **σ -aditivnosti** (prebrojive aditivnosti):

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n), \quad \text{ako je } A_n A_m = \emptyset \text{ za sve } n \neq m.$$

10. Nепреkinutost vjerojatnosti

Nепреkinutost vjerojatnosti

Teorem 1.1. *Neka je P vjerojatnost na σ -algebri \mathcal{F} . P je σ -aditivna ako i samo ako vrijedi*

$$A_1 \subset A_2 \subset \dots \implies \lim_{n \rightarrow \infty} P(A_n) = P\left(\bigcup_{n=1}^{\infty} A_n\right). \quad (1)$$

11. Geometrijska vjerojatnost

Geometrijska vjerojatnost

Neka je Ω ograničeni podskup n -dimenzionalnog prostora \mathbf{R}^n ($n = 1, 2, 3$). Pretpostavit ćemo da je Ω izmjeriv skup, tj. da postoji njegova mjera $m(\Omega)$ (duljina za $n = 1$, površina za $n = 2$, obujam za $n = 3$). Neka je A izmjeriv podskup od Ω . Kažemo da biramo točku **na sreću** unutar skupa Ω , ako je vjerojatnost da ona bude izabrana unutar podskupa A jednaka

$$P(A) = \frac{m(A)}{m(\Omega)}. \quad (1)$$

Ovako definiranu vjerojatnost nazivamo **geometrijska vjerojatnost**.

2. UVJETNA VJEROJATNOST

1. Uvjetna vjerojatnost

Uvjetna vjerojatnost

Neka je $B \in \mathcal{F}$ događaj pozitivne vjerojatnosti: $P(B) > 0$. **Uvjetna vjerojatnost** uz uvjet B je funkcija $P_B : \mathcal{F} \rightarrow [0, 1]$ definirana formulom

$$P_B(A) := \frac{P(AB)}{P(B)}, \quad \forall A \in \mathcal{F}. \quad (1)$$

Lako se je uvjeriti da je formulom (1) uistinu definirana vjerojatnosna funkcija. Naime vrijedi,

$$P_B(\Omega) = \frac{P(B \cap \Omega)}{P(B)} = \frac{P(B)}{P(B)} = 1$$

i slično za $P(\emptyset)$. Monotonost i aditivnost dokazuju se također po definiciji (1), korištenjem istovjetnih svojstava vjerojatnosne funkcije P .

2. VJEROJATNOST UMNOŠKA

Vjerojatnost umnoška

Vjerojatnost umnoška dvaju događaja računa se formulom

$$P(AB) = P(B)P(A | B) \quad (2)$$

Ako zamijenimo događaje A i B (koji oboje imaju pozitivnu vjerojatnost), dobit ćemo istovrsnu formulu

$$P(AB) = P(A)P(B | A). \quad (3)$$

3. Definicija i kriterij nezavisnosti događaja

Definicija i kriterij nezavisnosti događaja

Za događaje A i B kažemo da su **nezavisni**, ako vrijedi bilo koja od jednakosti: $P(A | B) = P(A)$ ili $P(B | A) = P(B)$.

Nuždan i dovoljan uvjet za nezavisnost jest da bude:

$$P(AB) = P(A)P(B). \quad (1)$$

4. Nezavisnost događaja

Nezavisnost događaja

Događaji A_1, A_2, \dots, A_n su **nezavisni** ako za svaki k , $2 \leq k \leq n$ i svaki izbor $A_{i_1}, A_{i_2}, \dots, A_{i_k}$ nekolicine tih događaja vrijedi

$$P(A_{i_1}A_{i_2} \cdots A_{i_k}) = P(A_{i_1})P(A_{i_2}) \cdots P(A_{i_k}).$$

5. Nezavisnost događaja A,B,C

Neka su A , B i C nezavisni. Onda vrijedi, na primjer

$$P(AB) = P(A)P(B),$$

pa su A i B nezavisni. Pročitavši još jednom definiciju, zaključujemo da su događaji u svakom podskupu skupa nezavisnih događaja također nezavisni.

Računajmo sad uvjetnu vjerojatnost sljedećeg tipa:

$$P(A | BC) = \frac{P(ABC)}{P(BC)} = \frac{P(A)P(B)P(C)}{P(B)P(C)} = P(A).$$

Vidimo da je uvjetna vjerojatnost jednaka bezuvjetnoj.

Ako su A , B i C po volji odabrani događaji, onda imamo

$$P(ABC) = P(A) \cdot P(B | A) \cdot P(C | AB).$$

Nezavisnost triju događaja znači da će sve uvjetne vjerojatnosti u kojima se ti događaji javljaju biti jednake bezuvjetnima: $P(B | A) = P(B)$, $P(C | AB) = P(C)$ i slično za druge moguće kombinacije. Tako za nezavisne događaje A , B i C vrijedi

$$P(ABC) = P(A)P(B)P(C).$$

Naglasimo da obrnuta tvrdnja nije istinita: ako je za tri događaja vjerojatnost umnoška događaja jednaka umnošku vjerojatnosti, oni ne moraju biti nezavisni.

* * *

6. Formula potpune vjerojatnosti

Neka je $A \subset \Omega$ bilo koji događaj. Familijom H_1, \dots, H_n i on je razbijen na događaje:

$$A = AH_1 \cup AH_2 \cup \dots \cup AH_n.$$

Kako su događaji AH_i međusobno disjunktni, vrijedi:

$$\begin{aligned} P(A) &= P(AH_1) + P(AH_2) + \dots + P(AH_n) \\ &= P(H_1)P(A | H_1) + \dots + P(H_n)P(A | H_n). \end{aligned}$$

Formula potpune vjerojatnosti

Neka je $\{H_1, \dots, H_n\}$ potpun sustav događaja. Za svaki događaj $A \subset \Omega$ vrijedi

$$P(A) = \sum_{i=1}^n P(H_i)P(A | H_i).$$

7. Bayesova formula

Bayesova formula

Vrijedi

$$P(H_i | A) = \frac{P(H_i)P(A | H_i)}{\sum_{j=1}^n P(H_j)P(A | H_j)}.$$

3. DISKRETNE SLUČAJNE VARIJABLE I VEKTORI

1. Slučajna varijabla

Slučajna varijabla

Preslikavanje $X : \Omega \rightarrow S$ je **diskretna slučajna varijabla** ako je za svaki $x_k \in S$ skup $A_k := (\omega \in \Omega : X(\omega) = x_k)$ događaj. Označimo

$$p_k := P(A_k) = P(X = x_k). \quad (1)$$

Za ove brojeve vrijedi $p_k > 0$, $\sum p_k = 1$. **Zakon razdiobe** slučajne varijable X sastoji se od područja vrijednosti koje ona poprima i odgovarajućih vjerojatnosti. Pišemo

$$X \sim \begin{pmatrix} x_1 & x_2 & x_3 & \dots \\ p_1 & p_2 & p_3 & \dots \end{pmatrix}. \quad (2)$$

2. Nezavisne slučajne varijable – definicija i temeljno svojstvo

Nezavisne slučajne varijable — definicija i temeljno svojstvo

Slučajne varijable $X, Y : \Omega \rightarrow S$ su **nezavisne** ako za sve $x_k, y_j \in S$ vrijedi

$$P(X = x_k, Y = y_j) = P(X = x_k)P(Y = y_j) \quad (3)$$

Tada vrijedi općenitije, za sve $A, B \subset S$

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B). \quad (4)$$

3. Očekivanje

Očekivanje slučajne varijable

Neka slučajna varijabla X ima zakon razdiobe:

$$X \sim \begin{pmatrix} x_1 & x_2 & x_3 & \dots \\ p_1 & p_2 & p_3 & \dots \end{pmatrix}.$$

Očekivanje slučajne varijable X definirano je kao zbroj

$$E(X) := \sum_k x_k p_k. \quad (1)$$

Često se očekivanje slučajne varijable označava i simbolima \bar{x} ili m_X .

4. Svojstva očekivanja

Teorem 3.1. *Neka je X i Y slučajne varijable definirane na istom vjerojatnosnom prostoru. Očekivanje ima svojstvo linearnosti, za sve realne brojeve s i t vrijedi*

$$E(sX + tY) = sE(X) + tE(Y).$$

Ako su varijable X i Y nezavisne, tada vrijedi

$$E(XY) = E(X)E(Y).$$

Dokaz. Svojstvo $E(sX) = sE(X)$ slijedi direktno iz definicije očekivanja:

$$E(sX) = \sum (sx_k)p_k = s \sum x_k p_k = sE(X).$$

Dokazat ćemo sad da vrijedi $E(X + Y) = E(X) + E(Y)$. Time će prva tvrdnja u teoremu biti dokazana.

Slučajna varijabla $X + Y$ poprima vrijednosti $x_j + y_k$ s vjerojatnošću p_{jk} . Zato je

$$\begin{aligned} E(X + Y) &= \sum_{k,j} (x_j + y_k)p_{kj} = \sum_{k,j} x_j p_{kj} + \sum_{k,j} y_k p_{kj} \\ &= \sum_j x_j \cdot \sum_k p_{kj} + \sum_k y_k \cdot \sum_j p_{kj} = \sum_j x_j p_j + \sum_k y_k q_k \\ &= E(X) + E(Y). \end{aligned}$$

Dokažimo sad drugu tvrdnju. Varijable X i Y su nezavisne, pa vrijedi $p_{jk} = p_j q_k$ za sve j i k . Zato je

$$\begin{aligned} E(XY) &= \sum_{j,k} x_j y_k p_{jk} = \sum_{j,k} x_j y_k p_j q_k \\ &= \left(\sum_j x_j p_j \right) \left(\sum_k y_k q_k \right) = E(X)E(Y). \quad \triangleleft \end{aligned}$$

5. Ishodišni i centralni moment slučajne varijable

Ishodišni i centralni momenti slučajne varijable

Neka slučajna varijabla X ima zakon razdiobe:

$$X \sim \begin{pmatrix} x_1 & x_2 & x_3 & \dots \\ p_1 & p_2 & p_3 & \dots \end{pmatrix}$$

i neka je n prirodni broj. **Ishodišni moment reda n** slučajne varijable X definirano se formulom

$$E(X^n) := \sum_k x_k^n p_k. \quad (2)$$

Ako je m_X očekivanje od X , onda se **centralni moment μ_n reda n** definira formulom

$$\mu_n := E[(X - m_X)^n] = \sum_k (x_k - m_X)^n p_k. \quad (3)$$

6. Disperzija

Disperzija slučajne varijable

Disperzija (rasipanje, varijanca) slučajne varijable X definira se formulom

$$D(X) = E[(X - m_X)^2]$$

Ovaj se izraz najčešće računa na način:

$$D(X) = E(X^2) - m_X^2 = \sum_k x_k^2 p_k - \left(\sum_k x_k p_k \right)^2,$$

Jednakost ovih dviju formula slijedi iz svojstva linearnosti očekivanja:

$$E[(X - m_X)^2] = E[X^2 - 2Xm_X + m_X^2] = E(X^2) - 2m_X E(X) + m_X^2 = E(X^2) - m_X^2.$$

7. Svojstva disperzije

Svojstva disperzije

Teorem 3.2. Za slučajnu varijablu X i realni broj s vrijedi

$$D(sX) = s^2 D(X).$$

Ako su X i Y nezavisne slučajne varijable, onda vrijedi

$$D(X + Y) = D(X) + D(Y).$$

Dokaz. Koristit ćemo svojstva očekivanja. Za prvu formulu dobivamo

$$\begin{aligned} D(sX) &= E[(sX)^2] - [E(sX)]^2 = E(s^2X^2) - [sE(X)]^2 \\ &= s^2E(X^2) - s^2[E(X)]^2 = s^2D(X). \end{aligned}$$

Ako su X i Y nezavisne, onda imamo

$$\begin{aligned} D(X + Y) &= E[(X + Y)^2] - [E(X + Y)]^2 \\ &= E(X^2) + 2E(XY) + E(Y^2) - E(X)^2 - 2E(X)E(Y) - E(Y^2) \\ &= E(X^2) - E(X)^2 + E(Y^2) - E(Y)^2 \\ &= D(X) + D(Y). \quad \triangleleft \end{aligned}$$

8. Kovariacijski moment. Koeficijent korelacije

Kovarijacijski moment. Koeficijent korelacije

Kovarijacijski moment varijabli X i Y definira se formulom

$$\text{cov}(X, Y) := E[(X - m_X)(Y - m_Y)] = E(XY) - m_X m_Y.$$

Koeficijent korelacije definira se formulom

$$r(X, Y) := \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}.$$

9. Disperzija zbroja slučajnih varijabli

Disperzija zbroja slučajnih varijabli

Teorem 3.3. *Disperzija zbroja $S = X_1 + \dots + X_n$ slučajnih varijabli računa se formulom*

$$D(S) = \sum_{i=1}^n D(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j).$$

Dokaz. Vrijedi $m_S = m_{X_1} + \dots + m_{X_n}$ pa je

$$\begin{aligned} D(S) &= E[(S - m_S)^2] = E\left(\sum_{i=1}^n (X_i - m_{X_i})\right)^2 \\ &= \sum_{i=1}^n E(X_i - m_{X_i})^2 + \sum_{i \neq j} E[(X_i - m_{X_i})(X_j - m_{X_j})] \\ &= \sum_{i=1}^n D(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j). \quad \triangleleft \end{aligned}$$

10. Svojstva koeficijenta korelacije

Svojstva koeficijenta korelacije

Teorem 3.4. *Za koeficijent korelacije uvijek je ispunjeno*

$$|r(X, Y)| \leq 1.$$

Jednakost $r(X, Y) = \pm 1$ vrijedi onda i samo onda kad je $Y = aX + b$ za neke konstante a i b .

Dokaz. Neka su X^* , Y^* normirane slučajne varijable pridružene varijablama X i Y . Onda imamo

$$D(X^* \pm Y^*) = D(X^*) + D(Y^*) \pm 2 \text{cov}(X^*, Y^*) = 2[1 \pm r(X, Y)].$$

Lijeva strana je uvijek pozitivna, pa je zato pozitivna i desna. Odatle slijedi

$$|r(X, Y)| \leq 1.$$

Nadalje, jednakost $r(X, Y) = 1$ vrijedit će samo onda kad bude $D(X^* - Y^*) = 0$. To je moguće samo kad je slučajna varijabla $X^* - Y^*$ jednaka konstanti. Odavde zaključujemo da mora biti

$$\frac{Y - m_Y}{\sigma_Y} - \frac{X - m_X}{\sigma_X} = \text{const}$$

odnosno

$$Y = aX + b,$$

pri čemu je $a = \sigma_Y/\sigma_X$ i b neki realni broj.

Slično zaključujemo i u slučaju kad je $r(X, Y) = -1$. \triangleleft

11. Karakteristična funkcija

Karakteristična funkcija

Karakteristična funkcija slučajne varijable X definira se formulom

$$\vartheta_X(t) := E(e^{itX})$$

Dakle,

$$\vartheta_X(t) = \sum_k p_k e^{itx_k}. \quad (4)$$

12. Svojstva karakteristične funkcije

Svojstva karakteristične funkcije

1° Karakteristična funkcija jednoznačno određuje razdiobu: dvije različite razdiobe ne mogu imati istu karakterističnu funkciju.

2° Ako su X_1, \dots, X_n nezavisne, tada je

$$\vartheta_{X_1 + \dots + X_n}(t) = \vartheta_{X_1}(t) \cdots \vartheta_{X_n}(t). \quad (5)$$

3° Vrijedi formula

$$E(X^r) = \frac{\vartheta^{(r)}(0)}{i^r}, \quad r = 1, 2, \dots \quad (6)$$

ukoliko očekivanje postoji. Posebice,

$$\begin{aligned} E(X) &= -i\vartheta'(0), \\ D(X) &= -\vartheta''(0) + \vartheta'(0)^2. \end{aligned} \quad (7)$$

4. PRIMJERI DISKRETNIH RAZDIOBA

1. Geometrijska razdioba – karakteristična funkcija, očekivanje i disperzija

Odredimo najprije karakterističnu funkciju geometrijske razdiobe:

$$\vartheta(t) = \sum_{k=1}^{\infty} e^{itk} \cdot pq^k = pe^{it} \sum_{k=0}^{\infty} (qe^{it})^k = \frac{pe^{it}}{1 - qe^{it}}.$$

Iskoristimo tu funkciju da izračunamo očekivanje ove razdiobe. Vrijedi

$$\vartheta'(t) = \frac{ipe^{it}}{(1 - qe^{it})^2}$$

pa je

$$E(X) = -i\vartheta'(0) = \frac{p}{(1 - q)^2} = \frac{1}{p}.$$

2. Geometrijska razdioba - odsustvo pamćenja

Odsustvo pamćenja — temeljno svojstvo geometrijske razdiobe

Teorem 4.1. *Slučajna varijabla X koja poprima vrijednosti u skupu $\{1, 2, 3, \dots\}$ ima geometrijsku razdiobu onda i samo onda ako vrijedi za sve $k, m \geq 1$*

$$P(X = k + m \mid X > k) = P(X = m). \quad (1)$$

Dokaz. Jedan je smjer jednostavan: ako X ima geometrijsku razdiobu, onda je

$$\begin{aligned} P(X = k + m \mid X > k) &= \frac{P(X = k + m, X > k)}{P(X > k)} = \frac{P(X = k + m)}{P(X > k)} \\ &= \frac{p(1 - p)^{k+m-1}}{(1 - p)^k} = p(1 - p)^{m-1} = P(X = m). \end{aligned}$$

3. Binomna razdioba – očekivanje, disperzija

Odredimo najprije karakterističnu funkciju binomne razdiobe. Neka je $X \sim \mathcal{B}(n, p)$. Tada imamo

$$\begin{aligned} \vartheta(t) &= \sum_{k=0}^n e^{itk} p_k = \sum_{k=0}^n e^{itk} \binom{n}{k} p^k q^{n-k} \\ &= \sum_{k=0}^n \binom{n}{k} (pe^{it})^k q^{n-k} = (pe^{it} + q)^n. \end{aligned}$$

Po formuli (7) vrijedi

$$\vartheta'(t) = n(pe^{it} + q)^{n-1}pe^{it}i,$$

$$\vartheta'(0) = n(p + q)^{n-1}pi = npi \implies E(X) = np.$$

Na isti način dobivamo

$$\vartheta''(0) = n(n-1)p^2i^2 + npi^2 = -n(n-1)p^2 - np$$

te je

$$D(X) = -\vartheta''(0) + \vartheta'(0)^2 = n(n-1)p^2 + np - n^2p^2 = np - np^2 = npq.$$

Binomna razdioba, definicija i numeričke karakteristike

Kažemo da slučajna varijabla X ima **binomnu razdiobu** s parametrima n i p i pišemo $X \sim \mathcal{B}(n, p)$, ako X poprima vrijedosti unutar skupa $\{0, 1, 2, \dots, n\}$ s vjerojatnostima

$$p_k = P(X = k) = \binom{n}{k}p^k(1-p)^{n-k}.$$

Očekivanje i disperzija binomne razdiobe su

$$m_X = np, \quad \sigma_X^2 = npq.$$

4. Stabilnost binomne razdiobe

Ako su $X_1 \sim \mathcal{B}(n_1, p)$ i $X_2 \sim \mathcal{B}(n_2, p)$ nezavisne binomne slučajne varijable, onda je $X_1 + X_2$ binomna slučajna varijabla. Odredimo njezine parametre.

Vrijedi $\vartheta_{X_1}(t) = (q + pe^{it})^{n_1}$, $\vartheta_{X_2}(t) = (q + pe^{it})^{n_2}$ te je zbog nezavisnosti od X_1 i X_2

$$\vartheta_{X_1+X_2}(t) = \vartheta_{X_1}(t)\vartheta_{X_2}(t) = (q + pe^{it})^{n_1+n_2}$$

a to je karakteristična funkcija binomne razdiobe $\mathcal{B}(n_1 + n_2, p)$.

5. Aproksimacija binomne razdiobe

Aproksimacija binomne razdiobe

Teorem 4.2. Neka je n velik a p malen. Označimo $\lambda = np$. tad vrijedi aproksimacija

$$\binom{n}{k} p^k q^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}. \quad (1)$$

Dokaz. Označimo $m = \frac{1}{p}$ i transformirajmo izraz slijeva:

$$\binom{n}{k} p^k (1-p)^{n-k} = \binom{n}{k} \left(\frac{1}{m}\right)^k \left(1 - \frac{1}{m}\right)^{n-k}$$

Sada je $\lambda = np = \frac{n}{m}$. Pustimo da broj n neograničeno raste:

$$\begin{aligned} \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} &= \frac{1}{k!} \frac{n(n-1) \cdots (n-k+1)}{n^k} \lambda^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &= \frac{1}{k!} \cdot 1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \lambda^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &\rightarrow \frac{\lambda^k}{k!} e^{-\lambda}. \quad \triangleleft \end{aligned}$$

6. Poissonova razdioba

Poissonova razdioba, definicija i numeričke karakteristike

Kažemo da slučajna varijabla X ima **Poissonovu razdiobu** s parametrom $\lambda > 0$ i pišemo $X \sim \mathcal{P}(\lambda)$ ako ona poprima vrijednosti unutar skupa $\{0, 1, 2, \dots\}$ s vjerojatnostima

$$p_k = P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

Za očekivanje i disperziju ove razdiobe vrijedi

$$m_X = \lambda, \quad \sigma_X^2 = \lambda.$$

7. Poisson – karakteristična funkcija, očekivanje, disperzija

Odredimo najprije karakterističnu funkciju Poissonove razdiobe $\mathcal{P}(\lambda)$.

$$\vartheta(t) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^{it})^k}{k!} = e^{-\lambda} e^{\lambda e^{it}} = e^{\lambda(e^{it}-1)}.$$

Odavde, na temelju veze karakteristične funkcije i momenata slučajne varijable, dobivamo $E(X) = \lambda$, $D(X) = \lambda$.

8. Stabilnost Poisson

Ako su $X_1 \sim \mathcal{P}(\lambda_1)$ i $X_2 \sim \mathcal{P}(\lambda_2)$ nezavisne slučajne varijable, onda je $X_1 + X_2$ također Poissonova slučajna varijabla. Dokažimo tu tvrdnju i odredimo parametar ove razdiobe.

Karakteristična funkcija Poissonove razdiobe je

$$\vartheta_{X_k}(t) = e^{\lambda_k(e^{it}-1)}, \quad k = 1, 2$$

te slijedi

$$\vartheta_{X_1+X_2} = e^{(\lambda_1+\lambda_2)(e^{it}-1)}$$

što je karakteristična funkcija Poissonove razdiobe $P(\lambda_1 + \lambda_2)$.

5. NEPREKINUTE SLUČAJNE VARIJABLE

1. Funkcija razdiobe

Funkcija razdiobe

Teorem 5.1. *Neka je F funkcija razdiobe slučajne varijable X . Ona posjeduje svojstva:*

$$1^\circ P(\{x_1 \leq X < x_2\}) = F(x_2) - F(x_1),$$

$$2^\circ F \text{ je neopadajuća: } x_1 < x_2 \implies F(x_1) \leq F(x_2),$$

$$3^\circ \lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1,$$

$$4^\circ F \text{ je neprekinuta slijeva:}$$

$$F(x - 0) := \lim_{\varepsilon \downarrow 0} F(x - \varepsilon) = F(x), \quad \forall x \in \mathbf{R}.$$

Dokaz.

1° Neka je $x_1 < x_2$. Onda vrijedi

$$\begin{aligned} F(x_2) &= P(\{X < x_2\}) = P(\{X < x_1\} \cup \{x_1 \leq X < x_2\}) \\ &= P(\{X < x_1\}) + P(\{x_1 \leq X < x_2\}) \\ &= F(x_1) + P(\{x_1 \leq X < x_2\}). \end{aligned}$$

2° Neka je ponovo $x_1 < x_2$. Kako vrijedi $\{X < x_1\} \subset \{X < x_2\}$, tvrdnja slijedi zbog monotonosti vjerojatnosti.

3° Neka je (x_n) po volji odabran padajući niz realnih brojeva, $\lim_{n \rightarrow \infty} x_n = -\infty$. Označimo $A_n = \{X < x_n\}$. Onda su A_n padajući skupovi: $A_1 \supset A_2 \supset \dots$ i vrijedi $\bigcap_{n=1}^{\infty} A_n = \emptyset$. Zato je, zbog svojstva neprekinutosti vjerojatnosti,

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{n \rightarrow \infty} F(x_n) = \lim_{n \rightarrow \infty} P(A_n) = 0.$$

Druga se tvrdnja dokazuje na isti način.

4° Tvrdnja ponovo slijedi iz neprekinutosti vjerojatnosti. Naime, ako je (ε_n) niz pozitivnih brojeva koji opada prema nuli, onda je s $A_n = \{X < x - \varepsilon_n\}$ definiran rastući niz skupova za koji vrijedi $\bigcup_{n=1}^{\infty} A_n = \{X < x\}$ pa tvrdnja slijedi zbog neprekinutosti vjerojatnosti:

$$\begin{aligned} F(x - 0) &= \lim_{\varepsilon \downarrow 0} F(x - \varepsilon) = \lim_{n \rightarrow \infty} F(x - \varepsilon_n) \\ &= \lim_{n \rightarrow \infty} P(A_n) = P(A) = F(x), \quad \forall x \in \mathbf{R}. \quad \triangleleft \end{aligned}$$

2. Gustoća razdiobe

Neprekinute slučajne varijable. Gustoća razdiobe

Za slučajnu varijablu X kažemo da je **neprekinuta** (kontinuirana) ako postoji nenegativna funkcija $f : \mathbf{R} \rightarrow \mathbf{R}$ takva da vrijedi

$$F(x) = \int_{-\infty}^x f(t) dt. \quad (5.2)$$

Funkcija f naziva se **gustoća razdiobe vjerojatnosti** slučajne varijable X . Ona nije nužno neprekinuta, no u točkama neprekinutosti od f vrijedi

$$f(x) = \frac{dF(x)}{dx}. \quad (5.3)$$

3. Jednolika razdioba

Jednolika razdioba, alternativna definicija, razdioba i gustoća

Za slučajnu varijablu X kažemo da je **jednoliko (uniformno)** distribuirana na intervalu $[a, b]$, ako je zadana funkcijom razdiobe odnosno funkcijom gustoće:

$$F(x) = \frac{x - a}{b - a}, \quad a \leq x \leq b,$$
$$f(x) = \frac{1}{b - a}, \quad a \leq x \leq b.$$

Pišemo $X \sim \mathcal{U}(a, b)$.

4. Nezavisnost

Definicija nezavisnosti

Kažemo da su slučajne varijable X i Y **nezavisne**, ukoliko za sve intervale A, B iz skupa \mathbf{R} vrijedi

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B).$$

5. Očekivanje, disprezija

Neka je X neprekinuta s gustoćom f . Njezino očekivanje definira se na način

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx \quad (5.6)$$

Ako ovaj nepravilni integral ne konvergira, očekivanje ne postoji.

Označimo $\bar{x} = E(X)$. Disperzija $D(X)$ slučajne varijable X računa se uz pomoć formula:

$$D(X) = E[(X - \bar{x})^2] = E(X^2) - \bar{x}^2.$$

Dakle

$$D(X) = \int_{-\infty}^{\infty} (x - \bar{x})^2 f(x) dx = \int_{-\infty}^{\infty} x^2 f(x) dx - \bar{x}^2. \quad (5.7)$$

Od svojstava očekivanja i disperzije izdvojit ćemo samo najvažnija:

6. Svojstva očekivanja i disperzije

Svojstva očekivanja i disperzije

Za sve slučajne varijable X , Y i realne brojeve s , t vrijedi

$$E(sX + tY) = sE(X) + tE(Y)$$

(svojstvo **linearnosti** očekivanja). Za disperziju pak vrijedi

$$D(sX) = s^2 D(X).$$

Ako su X i Y nezavisne, onda vrijedi

$$E(XY) = E(X)E(Y),$$

$$D(X + Y) = D(X) + D(Y).$$

7. Transformacija funkcije gustoće


Ako je ψ monotonno rastuća, tada je (slika 5.15)

$$A_y = \psi^{-1}\{\langle -\infty, y \rangle\} = \langle -\infty, \psi^{-1}(y) \rangle = \langle -\infty, x \rangle.$$

Oдавde dobivamo

$$G(y) = P(X \in A_y) = P(X \in \langle -\infty, x \rangle) = P(X < x) = F(x),$$

$$g(y) = \frac{d}{dy}G(y) = \frac{d}{dx}F(x) \cdot \frac{dx}{dy} = f(x) \frac{dx}{dy}.$$



Sl. 5.15.

Za monotonno padajuću funkciju ψ dobivamo (slika 5.15)

$$A_y = \psi^{-1}\{\langle -\infty, y \rangle\} = \langle \psi^{-1}(y), \infty \rangle = \langle x, \infty \rangle,$$

$$G(y) = P(X \in A_y) = P(X \in \langle x, \infty \rangle) = P(X > x) = 1 - F(x),$$

$$g(y) = \frac{d}{dy}G(y) = \frac{d}{dx}[1 - F(x)] \frac{dx}{dy} = -f(x) \frac{dx}{dy}.$$

U oba slučaja se rezultat može napisati istom formulom:

Transformacija funkcije gustoće

Neka je $Y = \psi(X)$. Ako je funkcija ψ rastuća ili padajuća funkcija, onda vrijedi

$$g(y) = f(x) \left| \frac{dx}{dy} \right|, \quad y = \psi(x), \quad (5.1)$$

tj.

$$g(y) = f(\psi^{-1}(y)) \left| \frac{d\psi^{-1}(y)}{dy} \right|.$$

Općenitije, ova formula vrijedi za svaku injektivnu funkciju ψ .

6. PRIMJERI NEPREKINUTIH RAZDIOBA

1. Eksponencijalna razdioba

Eksponencijalna razdioba, definicija

Kažemo da slučajna varijabla X ima **eksponencijalnu razdiobu** s parametrom $\lambda > 0$ ako ona poprima pozitivne vrijednosti s gustoćom

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0. \quad (6.1)$$

Pišemo $X \sim \mathcal{E}(\lambda)$. Njezina je funkcija razdiobe

$$F(x) = 1 - e^{-\lambda x}, \quad x > 0.$$

2. Fizikalni opis eksponencijalne razdiobe

Eksponencijalna razdioba, izvod iz modela pojavljivanja

Teorem 6.1. *Pretpostavimo da je uvjetna vjerojatnost pojavljivanja događaja u nekom vrlo kratkom intervalu $(x, x + \Delta x)$, ako je poznato da se događaj nije pojavio do trenutka x , proporcionalna duljini tog podintervala i ne ovisi o vrijednosti x :*

$$P(X < x + \Delta x \mid X > x) = \lambda \Delta x + r, \quad \frac{r}{\Delta x} \rightarrow 0 \quad \text{kad} \quad \Delta x \rightarrow 0.$$

Tada je X slučajna varijabla distribuirana po eksponencijalnom zakonu $\mathcal{E}(\lambda)$.

Dokaz. Po formuli za uvjetnu vjerojatnost možemo napisati

$$P(X > x + \Delta x) = P(X > x) \cdot P(X > x + \Delta x \mid X > x).$$

Međutim, kako je

$$P(X > x + \Delta x \mid X > x) = 1 - P(X < x + \Delta x \mid X > x) = 1 - \lambda \Delta x - r,$$

dobivamo

$$P(X > x + \Delta x) = P(X > x)(1 - \lambda \Delta x - r).$$

Definirajmo funkciju

$$Q(x) := P(X > x) = 1 - F(x).$$

Ona zadovoljava relaciju

$$Q(x + \Delta x) - Q(x) = Q(x)[- \lambda \Delta x - r]$$

te je

$$\frac{dQ(x)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{Q(x + \Delta x) - Q(x)}{\Delta x} = \lim_{\Delta x \rightarrow 0} Q(x)[- \lambda - \frac{r}{\Delta x}] = -\lambda Q(x).$$

Rješenje ove diferencijalne jednadžbe je

$$Q(x) = C e^{-\lambda x}.$$

Konstantu C određujemo iz početnog uvjeta: $Q(0) = P\{X > 0\} = 1$. Odavde $C = 1$ i zato

$$F(x) = 1 - Q(x) = 1 - e^{-\lambda x},$$

te X zaista ima eksponencijalnu razdiobu $\mathcal{E}(\lambda)$. ◁

3. Eksponencijalna – očekivanje, disperzija

Laplaceov transformat eksponencijalne razdiobe $\mathcal{E}(\lambda)$ iznosi

$$\begin{aligned} f^*(s) &= \int_0^{\infty} e^{-sx} f(x) dx = \int_0^{\infty} e^{-sx} \lambda e^{-\lambda x} dx \\ &= \lambda \int_0^{\infty} e^{-(s+\lambda)x} dx = -\frac{\lambda}{s+\lambda} e^{-(s+\lambda)x} \Big|_{x=0}^{x=\infty} = \frac{\lambda}{s+\lambda} \end{aligned}$$

(Pri uvrštavanju gornje granice uvažavamo da je f^* definirana za $s > 0$.)

Karakterističnu funkciju eksponencijalne razdiobe možemo napisati pomoću poznate veze: $\vartheta(t) = f^*(-it)$:

$$\vartheta(t) = \frac{\lambda}{\lambda - it}.$$

Očekivanje eksponencijalne razdiobe izračunat ćemo iz veze momenata i Laplaceovog transformata

$$E(X) = -f^{*'}(0) = -\left(\frac{\lambda}{s+\lambda}\right)' \Big|_{s=0} = \frac{1}{\lambda}.$$

Ishodišni moment reda n računamo ovako:

$$\begin{aligned} E(X^n) &= (-1)^n f^{*(n)}(0) = (-1)^n \left(\frac{\lambda}{s+\lambda}\right)^{(n)} \Big|_{s=0} \\ &= \frac{n!\lambda}{(s+\lambda)^{n+1}} \Big|_{s=0} = \frac{n!}{\lambda^n}. \end{aligned}$$

Sad za **disperziju** vrijedi

$$D(X) = E(X^2) - (EX)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

4. Eksponencijalna – odsustvo pamćenja

Karakterizacija eksponencijalne razdiobe

Teorem 6.2. *Neka za slučajnu varijablu X koja uzima samo pozitivne vrijednosti za sve pozitivne x i t vrijedi*

$$P(X < x+t \mid X > t) = P(X < x). \quad (6.2)$$

Tada X ima eksponencijalnu razdiobu.

DOKAZ. Označimo $Q(x) := P(X > x) = 1 - F(x)$, gdje je F tražena funkcija razdiobe. Po pretpostavci je $Q(0) = P(X > 0) = 1$. Također, vrijedi $Q'(x) = -f(x) < 0$ za $x > 0$. Označimo $Q'(0) =: -\lambda$. Osnovnu relaciju (6.2) možemo napisati na način

$$1 - P(X > x + t | X > t) = 1 - P(X > x)$$

te je

$$\frac{P(X > x + t, X > t)}{P(X > t)} = P(X > x)$$

ili

$$P(X > x + t) = P(X > t)P(X > x).$$

Tako dobivamo funkcionalnu jednadžbu

$$Q(x + t) = Q(t)Q(x), \quad \forall t, x > 0 \quad (6.3)$$

Slučajnu varijablu tražimo u klasi neprekinutih varijabli. Zato možemo pretpostaviti da je Q diferencijabilna funkcija. Deriviranjem relacije (6.3) po varijabli t dobivamo

$$Q'(x + t) = Q'(t)Q(x).$$

Uvrštavanjem $t = 0$ slijedi

$$Q'(x) = Q'(0)Q(x) = -\lambda Q(x)$$

i odavde dobivamo $Q(x) = Ce^{-\lambda x}$. Kako je $Q(0) = 1$, dobivamo $C = 1$. Zato je

$$F(x) = 1 - Q(x) = 1 - e^{-\lambda x}. \quad \triangleleft$$

5. Normalna razdioba – definicija

Normalna razdioba, definicija

Slučajna varijabla X ima **normalnu razdiobu** s parametrima $a \in \mathbf{R}$ i $\sigma^2 > 0$ ako je X neprekinuta slučajna varijabla s gustoćom

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-a)^2}{2\sigma^2}\right). \quad (6.1)$$

Pišemo $X \sim \mathcal{N}(a, \sigma^2)$.

6. Jedinična normalna razdioba

Izaberemo li parametre $a = 0$ i $\sigma = 1$, dobivamo slučajnu varijablu $\mathcal{N}(0, 1)$ koja se zove **jedinična normalna razdioba**. Njezinu gustoću označavamo sa

$$\phi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2}. \quad (6.2)$$

Za pripadnu funkciju razdiobe Φ vrijedi

$$\Phi(u) = \int_{-\infty}^u \phi(t) dt = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^u e^{-\frac{1}{2}t^2} dt. \quad (6.3)$$

Ovaj integral nije elementaran, ne može se eksplicitno izraziti pomoću elementarnih funkcija.

Funkcija ϕ je parna, pa ima sljedeća svojstva:

$$\begin{aligned} \int_{-\infty}^0 \phi(t) dt &= \frac{1}{2} \int_{-\infty}^{\infty} \phi(t) dt = \frac{1}{2}, \\ \int_0^u \phi(t) dt &= \frac{1}{2} \int_{-u}^u \phi(t) dt. \end{aligned}$$

Sad možemo napisati

$$\begin{aligned} \Phi(u) &= \int_{-\infty}^u \phi(t) dt = \int_{-\infty}^0 \phi(t) dt + \int_0^u \phi(t) dt \\ &= \frac{1}{2} + \frac{1}{2} \int_{-u}^u \phi(t) dt = \frac{1}{2} [1 + \Phi^*(u)]. \end{aligned}$$

Dakle, funkcija razdiobe Φ može se prikazati pomoću funkcije

$$\Phi^*(u) = \frac{1}{\sqrt{2\pi}} \int_{-u}^u e^{-\frac{1}{2}t^2} dt. \quad (6.4)$$

7. Veza jedinične i općenite normalne razdiobe

Veza jedinične i opće normalne razdiobe

Jedinična i opća normalna razdioba mogu se dobiti jedna iz druge *linearnom transformacijom*:

$$\begin{aligned} X \sim \mathcal{N}(0, 1) &\implies a + \sigma X \sim \mathcal{N}(a, \sigma^2), \\ X \sim \mathcal{N}(a, \sigma^2) &\implies \frac{X - a}{\sigma} \sim \mathcal{N}(0, 1). \end{aligned}$$

8. Karakteristična funkcija

Odredimo karakterističnu funkciju normalne razdiobe $\mathcal{N}(a, \sigma^2)$.

Najprije ćemo odrediti karakterističnu funkciju jedinične normalne razdiobe $\mathcal{N}(0, 1)$.
Vrijedi

$$\vartheta(t) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} e^{itx} dx.$$

Deriviramo ovu funkciju i primijenimo parcijalnu integraciju

$$\begin{aligned}\vartheta'(t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} ix e^{-\frac{1}{2}x^2} e^{itx} dx \\ &= \frac{i}{\sqrt{2\pi}} \left(-e^{itx} e^{-\frac{1}{2}x^2} \Big|_{-\infty}^{\infty} + \int_{-\infty}^{\infty} it e^{itx} e^{-\frac{1}{2}x^2} dx \right) \\ &= -t \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-\frac{1}{2}x^2} dx = -t\vartheta(t).\end{aligned}$$

Prema tome, ϑ zadovoljava diferencijalnu jednadžbu

$$\frac{d\vartheta(t)}{dt} = -t\vartheta(t)$$

uz početni uvjet $\vartheta(0) = 1$, koji vrijedi za svaku karakterističnu funkciju.

$$\frac{d\vartheta(t)}{\vartheta(t)} = -t dt \implies \vartheta(t) = \vartheta(0) e^{-\frac{1}{2}t^2} = e^{-\frac{1}{2}t^2}.$$

Ako je $X \sim \mathcal{N}(0, 1)$, tada $a + \sigma X \sim \mathcal{N}(a, \sigma^2)$ i dobivamo karakterističnu funkciju opće normalne razdiobe $\mathcal{N}(a, \sigma^2)$:

$$\vartheta_{a+\sigma X}(t) = e^{ita} \vartheta_X(\sigma t) = e^{ita} e^{-\frac{1}{2}\sigma^2 t^2} = e^{ita - \frac{1}{2}\sigma^2 t^2}.$$

9. Očekivanje, disperzija normalne razdiobe

Izračunat ćemo očekivanje i disperziju, koristeći karakterističnu funkciju. Neka je $X \sim \mathcal{N}(a, \sigma^2)$. Vrijedi

$$\begin{aligned}\vartheta(t) &= e^{ita - \frac{1}{2}\sigma^2 t^2} \\ \vartheta'(t) &= (ia - \sigma^2 t) e^{ita - \frac{1}{2}\sigma^2 t^2}, & \vartheta'(0) &= ia \\ \vartheta''(t) &= [-\sigma^2 + (ia - \sigma^2 t)^2] e^{ita - \frac{1}{2}\sigma^2 t^2}, & \vartheta''(0) &= -\sigma^2 - a^2.\end{aligned}$$

Zato je

$$\begin{aligned}E(X) &= -i\vartheta'(0) = a, \\ D(X) &= -\vartheta''(0) + \vartheta'(0)^2 = \sigma^2.\end{aligned}$$

10. Vjerojatnost jedinične normalne razdiobe

Računanje vjerojatnosti za jediničnu normalnu razdiobu

Za jediničnu normalnu razdiobu X vrijedi:

$$P(u_1 < X < u_2) = \Phi(u_2) - \Phi(u_1) = \frac{1}{2} [\Phi^*(u_2) - \Phi^*(u_1)]. \quad (6.5)$$

Posebice, u slučaju simetričnog intervala

$$P(|X| < u) = \frac{1}{2} [\Phi^*(u) - \Phi^*(-u)] = \Phi^*(u). \quad (6.6)$$

11. Vjerojatnost općenite normalne razdiobe

Neka je $X \sim \mathcal{N}(a, \sigma^2)$. Tada je $\frac{X-a}{\sigma} \sim \mathcal{N}(0, 1)$ i funkciju razdiobe F varijable X možemo izraziti uz pomoć funkcije Φ :

$$F(x) = \Phi(u) = \frac{1}{2} [1 + \Phi^*(u)], \quad u = \frac{x-a}{\sigma}.$$


Tako računamo

$$\begin{aligned} P(x_1 < X < x_2) &= P\left(\frac{x_1-a}{\sigma} < \frac{X-a}{\sigma} < \frac{x_2-a}{\sigma}\right) \\ &= \Phi\left(\frac{x_2-a}{\sigma}\right) - \Phi\left(\frac{x_1-a}{\sigma}\right) = \frac{1}{2} \left[\Phi^*\left(\frac{x_2-a}{\sigma}\right) - \Phi^*\left(\frac{x_1-a}{\sigma}\right) \right]. \end{aligned}$$

12. Pravilo 3-sigma

Neka je $X \sim \mathcal{N}(a, \sigma^2)$ Izračunajmo

$$P(|X-a| < k\sigma), \quad k = 1, 2, 3.$$



Sl. 6.5.

Imamo

$$P(|X-a| < k\sigma) = P(-k\sigma < X-a < k\sigma) = P(-k < \tilde{X} < k) = \Phi^*(k).$$

Vrijedi $\Phi^*(1) = 0.6827$, $\Phi^*(2) = 0.9545$, $\Phi^*(3) = 0.9973$. Dakle, s vjerojatnošću 99.73% (odnosno, praktički sigurno) normalna varijabla uzima vrijednosti unutar intervala $(a-3\sigma, a+3\sigma)$. Ta se činjenica naziva *pravilo tri sigma*.

Teorem 6.3. *Neka su X_1 i X_2 nezavisne slučajne varijable s normalnim razdiobama*

$$X_1 \sim \mathcal{N}(a_1, \sigma_1^2), \quad X_2 \sim \mathcal{N}(a_2, \sigma_2^2)$$

i s_1, s_2 bilo koji realni brojevi. Tada vrijedi

$$s_1 X_1 + s_2 X_2 \sim \mathcal{N}(s_1 a_1 + s_2 a_2, s_1^2 \sigma_1^2 + s_2^2 \sigma_2^2).$$

Dokaz. Karakteristične funkcije slučajnih varijabli X_1 i X_2 su

$$\vartheta_{X_k}(t) = \exp(a_k t - \frac{1}{2} \sigma_k^2 t^2), \quad k = 1, 2.$$

Zato je

$$\vartheta_{s_k X_k}(t) = \exp(s_k a_k t - \frac{1}{2} s_k^2 \sigma_k^2 t^2), \quad k = 1, 2.$$

pa dobivamo

$$\vartheta_{s_1 X_1 + s_2 X_2}(t) = \exp((s_1 a_1 + s_2 a_2)t - \frac{1}{2}(s_1^2 \sigma_1^2 + s_2^2 \sigma_2^2)t^2),$$

što je karakteristična funkcija normalne razdiobe $\mathcal{N}(s_1 a_1 + s_2 a_2, s_1^2 \sigma_1^2 + s_2^2 \sigma_2^2)$. \triangleleft

7. SLUČAJNI VEKTORI

1. Gustoća razdiobe. Nепреkinuti slučajni vektori

Gustoća razdiobe. Nепреkinuti slučajni vektori

Za slučajan vektor (X_1, \dots, X_n) kažemo da je **непрекинут** ako postoji funkcija $f : \mathbf{R}^n \rightarrow [0, \infty)$ takva da za sve x_1, x_2, \dots, x_n vrijedi

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(u_1, \dots, u_n) du_1 \dots du_n. \quad (7.2)$$

Funkciju f nazivamo **gustoća razdiobe** slučajnog vektora. Tamo gdje je F diferencijabilna, vrijedi

$$f(x_1, \dots, x_n) := \frac{\partial^n F(x_1, \dots, x_n)}{\partial x_1 \cdots \partial x_n} \quad (7.3)$$

2. Vjerojatnost realizacije slučajnog vektora

Računanje vjerojatnosti realizacije slučajnog vektora

Za svaki izmjerivi skup $G \subset \mathbf{R}^n$ vrijedi

$$P((X_1, \dots, X_n) \in G) = \int_G \cdots \int f(x_1, \dots, x_n) dx_1 \cdots dx_n. \quad (7.4)$$

3. Marginalne gustoće

Za dvodimenzionalni slučajni vektor (X, Y) koristit ćemo jednostavnije oznake. Za gustoću vrijedi

$$f(x, y) := \frac{\partial^2 F(x, y)}{\partial x \partial y},$$

marginalne razdiobe:

$$F_X(x) := F(x, \infty) = \int_{-\infty}^x dx \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\infty}^x f_X(x) dx,$$
$$F_Y(y) := F(\infty, y) = \int_{-\infty}^y dy \int_{-\infty}^{\infty} f(x, y) dx = \int_{-\infty}^y f_Y(y) dy,$$

marginalne gustoće:

$$f_X(x) := \int_{-\infty}^{\infty} f(x, y) dy,$$
$$f_Y(y) := \int_{-\infty}^{\infty} f(x, y) dx.$$

Kriterij nezavisnosti za neprekinute slučajne vektore

Teorem 7.1. Komponente X_1, \dots, X_n neprekinutog slučajnog vektora (X_1, \dots, X_n) su nezavisne onda i samo onda ako vrijedi

$$f(x_1, \dots, x_n) = f_1(x_1) \cdot \dots \cdot f_n(x_n), \quad \forall (x_1, \dots, x_n) \in \mathbf{R}^n. \quad (7.6)$$

Dokaz. Jedan smjer slijedi iz (7.5), deriviranjem te jednakosti po varijablama x_1, \dots, x_n . Obrat ćemo, zbog jednostavnosti zapisivanja, dokazati za dvodimenzionalan vektor. Neka su A i B intervali u \mathbf{R} i $G = A \times B$ pravokutnik. Onda vrijedi

$$P(X \in A, Y \in B) = P((X, Y) \in G) = \iint_G f(x, y) dx dy$$

Prema (7.6), vrijedi $f(x, y) = f_X(x)f_Y(y)$, pa je ovaj integral jednak

$$\iint_G f_X(x)f_Y(y) dx dy = \int_A f_X(x) dx \cdot \int_B f_Y(y) dy = P(X \in A) \cdot P(Y \in B).$$

Dakle, X i Y su nezavisne. \triangleleft

5. Svojstva očekivanja

Svojstva očekivanja

Teorem 7.2. Za svake dvije slučajne varijable $X, Y : \Omega \rightarrow \mathbf{R}$ vrijedi

$$E(X + Y) = E(X) + E(Y). \quad (7.7)$$

Ako su X i Y nezavisne, onda je

$$E(XY) = E(X) \cdot E(Y). \quad (7.8)$$

Dokaz. Neka je $f(x, y)$ gustoća slučajnog vektora (X, Y) . Tada vrijedi

$$\begin{aligned} E(X + Y) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x + y) f(x, y) dx dy \\ &= \int_{-\infty}^{\infty} x dx \int_{-\infty}^{\infty} f(x, y) dy + \int_{-\infty}^{\infty} y dy \int_{-\infty}^{\infty} f(x, y) dx \\ &= \int_{-\infty}^{\infty} x f_X(x) dx + \int_{-\infty}^{\infty} y f_Y(y) dy \\ &= E(X) + E(Y). \end{aligned}$$

Pretpostavimo sad da su X i Y nezavisne. Tad se funkcija gustoće može faktori-
zitati: $f(x, y) = f_X(x)f_Y(y)$ pa vrijedi

$$\begin{aligned} E(XY) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y)dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf_X(x)f_Y(y)dx dy \\ &= \int_{-\infty}^{\infty} xf_X(x)dx \cdot \int_{-\infty}^{\infty} yf_Y(y)dy = E(X) \cdot E(Y). \end{aligned}$$

6. Svojstvo karakteristične funkcije

Svojstvo karakteristične funkcije

Teorem 7.3. *Ako su X i Y nezavisne slučajne varijable, za karakterističnu funkciju zbroja vrijedi*

$$\vartheta_{X+Y}(t) = \vartheta_X(t) \cdot \vartheta_Y(t).$$

7. Disperzija zbroja

Disperzija zbroja

Teorem 7.4. *Ako su X_1, X_2, \dots, X_n nekorelirane slučajne varijable, tada vrijedi*

$$D(X_1 + X_2 + \dots + X_n) = D(X_1) + D(X_2) + \dots + D(X_n).$$

Dokaz. Lijeva i desna strana se ne mijenjaju ako od varijabli oduzmemo očekivanje, zato možemo pretpostaviti da je $E(X_k) = 0$. Sad imamo

$$\begin{aligned} D\left(\sum_{k=1}^n X_k\right) &= E\left(\sum_{k=1}^n X_k\right)^2 = E\left(\sum_{j=1}^n \sum_{k=1}^n X_j X_k\right) \\ &= \sum_{j=1}^n \sum_{k=1}^n E(X_j X_k) = \sum_{k=1}^n E(X_k^2) + \sum_{j \neq k} E(X_j X_k) \\ &= \sum_{k=1}^n E(X_k^2) + \sum_{j \neq k} E(X_j)E(X_k) \\ &= \sum_{k=1}^n E(X_k^2) = \sum_{k=1}^n D(X_k). \quad \triangleleft \end{aligned}$$

Uvjetna gustoća

Neka je $f(x, y)$ gustoća razdiobe slučajnog vektora (X, Y) . Ako je poznata realizacija $Y = y$ varijable Y , tada se **uvjetna gustoća** varijable X uz uvjet $Y = y$ definira formulom

$$f_{X|Y=y}(x) := \frac{f(x, y)}{f_Y(y)} = \frac{f(x, y)}{\int_{-\infty}^{\infty} f(x, y) dy}. \quad (7.1)$$

Uglavnom pišemo jednostavnije $f(x | y)$, umjesto $f_{X|Y=y}(x)$.

Račun s uvjetnim vjerojatnostima omogućava nam lakše računanje vjerojatnosti, gustoća i očekivanja u slučaju kad realizacija događaja ili neke slučajne varijable ovisi o nekoj drugoj slučajnoj varijabli. Tu uvjetne gustoće igraju sličnu ulogu kao i uvjetne vjerojatnosti i hipoteze u formuli potpune vjerojatnosti. Tako dobivamo i analogne formule. Najprije, iz definicijske formule možemo zapisati

$$\begin{aligned} f(x, y) &= f(x | y)f_Y(y), \\ f(x, y) &= f(y | x)f_X(x). \end{aligned}$$

Marginalne gustoće dobivamo integriranjem lijeve strane ovih jednakosti:

Marginalne i uvjetne gustoće

Marginalne gustoće možemo računati formulama

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x | y)f_Y(y)dy, \\ f_Y(y) &= \int_{-\infty}^{\infty} f(y | x)f_X(x)dx. \end{aligned}$$

Uvjetne gustoće su također efikasno sredstvo u računanju očekivanja, pa i vjerojatnosti događaja (koji ovisi o mogućim realizacijama slučajne varijable:

Uvjetna očekivanja i vjerojatnosti

Očekivanje varijable X koja ovisi o realizacijama varijable Y :

$$E(X) = \int_{-\infty}^{\infty} E(X | Y=y)f_Y(y)dy. \quad (7.2)$$

Vjerojatnost događaja koji ovisi o realizacijama slučajne varijable X :

$$P(A) = \int_{-\infty}^{\infty} P(A | X=x)f_X(x)dx. \quad (7.3)$$

8. FUNKCIJE SLUČAJNIH VEKTORA

1. Transformacija gustoće pri bijektivnom preslikavanju.

Transformacija gustoća pri bijektivnom preslikavanju

$$g(y_1, \dots, y_n) = f(x_1, \dots, x_n) \cdot \left| \frac{\partial(x_1, \dots, x_n)}{\partial(y_1, \dots, y_n)} \right| \quad (8.3)$$

2. Gustoća funkcije slučajnog vektora

Preslikavanje $\psi : \mathbf{R}^2 \rightarrow \mathbf{R}$ ćemo nadopuniti do preslikavanja iz \mathbf{R}^2 u \mathbf{R}^2 , kako bismo mogli iskoristiti poznate veze između gustoća slučajnih vektora. Najjednostavnije je to učiniti tako da prvu komponentu vektora ostavimo nepromijenjenu. Tako dobivamo sustav:

$$\begin{aligned}x &= x, \\z &= \psi(x, y),\end{aligned}$$

Označimo preslikavanje inverzno ovome:

$$\begin{aligned}x &= x, \\y &= \chi(x, z).\end{aligned}$$

Jakobijan inverznog preslikavanja glasi

$$\frac{\partial(x, y)}{\partial(x, z)} = \begin{vmatrix} \frac{\partial x}{\partial x} & \frac{\partial x}{\partial z} \\ \frac{\partial y}{\partial x} & \frac{\partial y}{\partial z} \end{vmatrix} = \begin{vmatrix} 1 & 0 \\ \frac{\partial y}{\partial x} & \frac{\partial y}{\partial z} \end{vmatrix} = \frac{\partial y}{\partial z}.$$

Prema tome, po formuli (8.3), gustoća vektora (X, Z) je

$$g(x, z) = f(x, y) \left| \frac{\partial y}{\partial z} \right|,$$

Gustoću g_Z slučajne varijable Z možemo dobiti preko marginalne gustoće ovog vektora.

Gustoća funkcije slučajnog vektora

Gustoća slučajne varijable $Z = \psi(X, Y)$ dobiva se formulom

$$g_Z(z) = \int_{-\infty}^{\infty} f(x, y) \left| \frac{\partial y}{\partial z} \right| dx, \quad (8.4)$$

gdje je f gustoća vektora (X, Y) .

9. ZAKON VELIKIH BROJEVA I C.G.T.

1. Konvergencija po vjerojatnosti

Konvergencija po vjerojatnosti

Niz (X_n) konvergira **po vjerojatnosti** ka slučajnoj varijabli Y ako za svaki $\varepsilon > 0$ vrijedi

$$\lim_{n \rightarrow \infty} P(|X_n - Y| > \varepsilon) = 0. \quad (9.1)$$

Pišemo $X_n \xrightarrow{P} Y$.

2. Nejednakosti Markova i Čebiševa

Nejednakosti Markova i Čebiševa

Teorem 9.1. (Nejednakost Markova) Ako X poprima nenegativne vrijednosti, onda za svaki $\varepsilon > 0$ vrijedi

$$P(X \geq \varepsilon) \leq \frac{E(X)}{\varepsilon}.$$

(L_p **nejednakost**) Za svaku slučajnu varijablu X s očekivanjem m_X vrijedi

$$P(|X - m_X| \geq \varepsilon) \leq \frac{E(|X - m_X|^p)}{\varepsilon^p}.$$

(**Nejednakost Čebiševa**) Posebice, za $p = 2$, vrijedi

$$P(|X - m_X| \geq \varepsilon) \leq \frac{D(X)}{\varepsilon^2}.$$

Dokaz. Nejednakost Markova slijedi iz ocjene integrala:

$$P(X \geq a) = \int_{x \geq a} dF(x) \leq \int_{x \geq a} \frac{x}{a} dF(x) \leq \frac{1}{a} \int_0^\infty x dF(x) = \frac{1}{a} E(X).$$

Primjenimo tu ocjenu na pozitivnu slučajnu varijablu $|X - m_X|$. Imamo, za svaki $p > 0$:

$$P(|X - m_X| \geq \varepsilon) = P(|X - m_X|^p \geq \varepsilon^p) \leq \frac{E(|X - m_X|^p)}{\varepsilon^p}.$$

Za $p = 2$ dobivamo nejednakost Čebiševa. \triangleleft

3. Slabi zakon velikih brojeva

Slabi zakon velikih brojeva, definicija

Kažemo da niz X_1, X_2, \dots slučajnih varijabli zadovoljava **slabi zakon velikih brojeva** ako

$$\frac{1}{n} \sum_{k=1}^n (X_k - EX_k) \longrightarrow 0, \quad \text{kad } n \rightarrow \infty \quad (9.2)$$

po vjerojatnosti, tj. ako za svaki $\varepsilon > 0$ vrijedi

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n (X_k - EX_k)\right| > \varepsilon\right\} = 0. \quad (9.3)$$

4. Dovoljni uvjeti za slabi zakon velikih brojeva

Dovoljni uvjeti za slabi zakon velikih brojeva

Teorem 9.2. *Ako varijable X_1, X_2, \dots zadovoljavaju uvjet*

$$\lim_{n \rightarrow \infty} \frac{1}{n^2} D\left(\sum_{k=1}^n X_k\right) = 0,$$

tada on zadovoljava zakon velikih brojeva.

Taj će uvjet biti ispunjen ako su na primjer

- 1) X_1, X_2, \dots nekorelirane, s ograničenim varijancama.
- 2) X_1, X_2, \dots nezavisne s istom varijancom σ
- 3) X_1, X_2, \dots nezavisne s istom distribucijom i konačnom varijancom.

5. Konvergencija gotovo sigurno

Konvergencija gotovo sigurno

Niz (X_n) konvergira **gotovo sigurno** ka slučajnoj varijabli Y ako vrijedi

$$P\left(\lim_{n \rightarrow \infty} X_n = Y\right) = 1.$$

Pišemo $X_n \xrightarrow{\text{g.s.}} Y$, ili $X_n \longrightarrow Y$ g.s.

6. Usporedba konvergencija

Usporedba konvergencija

Teorem 9.3. *Ako niz slučajnih varijabli (X_n) konvergira gotovo sigurno prema slučajnoj varijabli Y , tada on konvergira prema istoj slučajnoj varijabli i po vjerojatnosti.*

7. Jaki zakon velikih brojeva

Jaki zakon velikih brojeva

Teorem 9.4. Neka su X_1, X_2, \dots nezavisne identički distribuirane slučajne varijable s konačnim očekivanjem m . Onda vrijedi

$$\frac{1}{n} \sum_{k=1}^n X_k \longrightarrow m \quad \text{s.s.}$$

8. Konvergencija po distribuciji

Konvergencija po distribuciji

Niz (X_n) konvergira **po distribuciji** ka slučajnoj varijabli X ako za odgovarajući niz funkcija razdiobe vrijedi

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x),$$

u svakoj točki x gdje je F_X neprekinuta. Pišemo $X_n \xrightarrow{\mathcal{D}} X$.

9. Centralni granični teorem

Centralni granični teorem

Teorem 9.7. Neka je (X_n) niz identički distribuiranih nezavisnih slučajnih varijabli s očekivanjem m i disperzijom σ^2 . Onda za normirani zbroj vrijedi

$$\frac{\sum_{k=1}^n (X_k - m)}{\sigma\sqrt{n}} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1).$$

Dokaz. Bez smanjenja općenitosti možemo pretpostaviti da je $m = 0$. Inače, varijable X_n možemo zamijeniti s centriranim, $X_n - m$ koje imaju istu disperziju.

Sve varijable imaju istu razdiobu, pa im je i karakteristična funkcija jednaka. Neka je ϑ karakteristična funkcija tih varijabli. Zbog nezavisnosti pribrojnika, karakteristična funkcija zbroja jednaka je umnošku karakterističnih funkcija:

$$\vartheta_{X_1 + \dots + X_n}(t) = \vartheta(t)^n.$$

Označimo $Z_n = \frac{1}{\sigma\sqrt{n}} \sum_{k=1}^n X_k$. Karakteristična funkcija te varijable jednaka je

$$\vartheta_{Z_n}(t) = \vartheta\left(\frac{t}{\sigma\sqrt{n}}\right)^n.$$

Prikažimo funkciju ϑ Taylorovim redom:

$$\vartheta(t) = c_0 + c_1 t + c_2 t^2 + R_2$$

Ostatak R_2 teži u nulu brže nego t^2 . Za svaku karakterističnu funkciju je $c_0 = \vartheta(0) = 1$. Druga dva koeficijenta su

$$c_1 = \vartheta'(0) = iE(X_1) = im = 0,$$

$$c_2 = \frac{1}{2}\vartheta''(0) = -\frac{1}{2}E(X_1^2) = -\frac{1}{2}\sigma^2.$$

Tako dobivamo:

$$\vartheta_{Z_n}(t) = \left[1 - \frac{1}{2}\sigma^2 \cdot \frac{t^2}{\sigma^2 \cdot n} + R_2 \right]^n = \left[1 - \frac{t^2}{2n} + R_2 \right]^n \longrightarrow e^{-t^2/2}. \quad \triangleleft$$

10. Teorem Moivre-Laplace

Teorem Moivre-Laplacea

Teorem 9.8. Normirana binomna razdioba teži po distribuciji k jediničnoj normalnoj razdiobi:

$$\frac{\mathcal{B}(n, p) - np}{\sqrt{npq}} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1)$$

Dokaz. Dovoljno je primjeniti centralni granični teorem na niz (I_k) indikatorskih slučajnih varijabli. Očekivanje ovih varijabli je p , a disperzija pq . Onda je

$$\sum_{k=1}^n (I_k - p) = X - np$$

pri čemu X ima binomnu razdiobu $\mathcal{B}(n, p)$. Tvrdnja sad slijedi iz prethodnog teorema.

10., 11., 12. CJELINE

1. Valjane statistike

Valjane statistike

Statistiku $\Theta_n = \Theta(X_1, X_2, \dots, X_n)$ nazivamo **valjanom** procjenom parametra ϑ ako za svaki $\varepsilon > 0$ slučajna varijabla Θ_n konvergira prema ϑ po vjerojatnosti:

$$\lim_{n \rightarrow \infty} P(|\Theta_n - \vartheta| < \varepsilon) \rightarrow 1.$$

Teorem 10.1. *Da bi nepristrana statistika bila valjana, dovoljno je da joj disperzija teži u nulu (kad n teži u beskonačnost).*

DOKAZ. Ta tvrdnja slijedi iz Čebiševljeve nejednakosti:

$$P(|\Theta_n - \vartheta| < \varepsilon) \geq 1 - \frac{E[(\Theta_n - \vartheta)^2]}{\varepsilon^2} = 1 - \frac{D(\Theta_n)}{\varepsilon^2} \rightarrow 1.$$

2. Kriterij najveće izglednosti

Kriterij najveće izglednosti

Neka je x_1, x_2, \dots, x_n realizacija uzorka populacije X , čija funkcija gustoće $f(\vartheta, x)$ ovisi o nepoznatom parametru ϑ . **Funkcija izglednosti**¹ definira se kao umnožak

$$L(\vartheta, x_1, \dots, x_n) := f(\vartheta, x_1)f(\vartheta, x_2) \cdots f(\vartheta, x_n). \quad (10.11)$$

Za procjenu parametra ϑ uzimamo onu vrijednost $\hat{\vartheta}$ za koju funkcija izglednosti poprima globalni maksimum.

3. Kvantil

Kvantil

Relan broj x_p za koji vrijedi

$$F(x_p) = p$$

to jest

$$\int_{-\infty}^{x_p} f(t) dt = p$$

naziva se **kvantil** reda p .

4. Nivo značajnosti

Nivo značajnosti

Za zadani broj p , $0 < p < 1$ koji određuje interval povjerenja, veličina $\alpha = 1 - p$ naziva se **nivo značajnosti (signifikantnosti)**. Pri tom za jednostrane kvantile vrijedi:

$$x_p = x_{1-\alpha}, \quad x_{1-p} = x_\alpha,$$

a za dvostrane:

$$x_{\frac{1}{2}(1-p)} = x_{\alpha/2}, \quad x_{\frac{1}{2}(1+p)} = x_{1-\alpha/2}.$$